

Signály a systémy

2025/2026

Music Information Retrieval

Boris Nicolas Dráb

xdrabbo00

10. 12. 2025

Brno

1. Úvod


Predmetom tohto projektu bolo navrhnuť a implementovať systém na vyhľadávanie hudobných nahrávok (Music Information Retrieval) inšpirovaný aplikáciou Shazam. Riešenie bolo budované postupne, od jednoduchého referenčného prístupu až po robustnejší systém založený na spektrogramovej reprezentácii signálu. Základom navrhnutého riešenia je krátkodobá Fourierova transformácia (STFT) a normalizácia spektrogramu.

2. Analýza signálu a dát

Hudobný signál je **časovo nestacionárny**, keďže jeho frekvenčné zloženie sa v čase mení. Z tohto dôvodu nie je vhodné analyzovať celý signál pomocou jednej Fourierovej transformácie. Na zachytenie časovo-frekvenčnej štruktúry signálu je použitá časovo-frekvenčná reprezentácia vo forme spektrogramu.

2.1 Časový priebeh signálu


Na úvod bol analyzovaný časový priebeh zvukového signálu. V časovej oblasti je možné pozorovať zmeny amplitúdy súvisiace s dynamikou hudby, avšak samotný časový priebeh neposkytuje dostatočné informácie na rozlíšenie jednotlivých hudobných nahrávok.



2.2 Spektrogram a krátkodobá Fourierova transformácia

Spektrogram bol získaný pomocou krátkodobej Fourierovej transformácie (STFT). Signál bol rozdelený na prekrývajúce sa časové okná s dĺžkou 512 vzoriek (približne 32 ms) a prekrytím 50%. Pre každé okno bola vypočítaná Fourierova transformácia realizovaná pomocou rýchlej Fourierovej transformácie (FFT) a použitá jej amplitúdová zložka.

$$X(m, k) = \sum_{n=-\infty}^{\infty} x[n]w[n-t]e^{-j2\pi kn/N}$$



Výsledkom je dvojrozmerná reprezentáciu signálu, kde jedna os zodpovedá času, druhá frekvencii a hodnota vyjadruje energiu signálu v danom frekvenčnom pásme.

2.3 Úprava spektrogramu

Pre zvýšenie robustnosti riešenia voči šumu a filtrovaniu boli na spektrograme aplikované nasledujúce úpravy:

- použitie **logaritmickkej mierky amplitúdy**, ktorá znižuje dynamický rozsah signálu,
- obmedzenie frekvenčného pásma na interval približne 300 – 3400 Hz (telefónne pásmo), kde sa nachádza väčšina relevantnej hudobnej informácie,
- normalizácia spektrogramu po frekvenčných kanáloch pomocou vydelenia priemernou hodnotou amplitúdy v čase, čím sa potláča vplyv globálnych frekvenčných zmien spôsobených filtrovaním alebo ekvalizáciou:

$$\tilde{S}(f, t) = \frac{S(f, t)}{\frac{1}{T} \sum_{t=1}^T S(f, t)}$$

Tieto modifikácie zabezpečujú, že porovnanie signálov je založené predovšetkým na **tvarovej frekvenčnej štruktúre** hudby, nie na absolútnej energii signálu.

3. Základné riešenie

Ako prvý krok bolo implementované jednoduché referenčné riešenie, ktoré slúžilo ako **baseline** pre ďalšie experimenty. Cieľom bolo overiť, či je možné identifikovať hudobné nahrávky na základe elementárnej časovo-frekvenčnej reprezentácie bez dodatočných úprav.

Pre každý testovací signál bol vypočítaný spektrogram pomocou STFT. Následne bol na známych nahrávkach aplikovaný časový posuv s cieľom nájsť päťsekundový úsek, ktorý najviac zodpovedá testovaciemu signálu. Podobnosť medzi signálmi bola určená pomocou skalárneho súčinu (korelácie) príslušných spektrogramov. Miera zhody bola vypočítaná ako:

$$s = \langle A, B \rangle = \sum_{i=1}^N A_i B_i$$

Tento prístup sa ukázal ako málo robustný.

3.1 Vyhodnotenie základného riešenia

Úspešnosť základného riešenia bola vyhodnotená na validačnej sade pomocou metrík Top-1 a Top-5 presnosti. Dosiahnuté výsledky boli približne:

- Top-1 accuracy: ~30-38 %
- Top-5 accuracy: ~40-45 %

Tieto hodnoty ukazujú, že základné riešenie dokázalo v niektorých prípadoch správne identifikovať hudobnú nahrávku, avšak jeho spoľahlivosť bola nedostatočná na praktické použitie.

3.2 Analýza obmedzení základného riešenia

Hlavné nedostatky základného riešenia možno zhrnúť nasledovne:

- porovnávanie spektrogramov bolo citlivé na **globálne zmeny amplitúdy**,
- riešenie nebolo dostatočne robustné voči **frekvenčnému skresleniu a šumu**,
- všetky frekvenčné zložky boli považované za rovnako dôležité, hoci časť spektra nenesie relevantnú hudobnú informáciu.

4. Postupné zlepšenie riešenia

Na základe analýzy obmedzení základného riešenia boli postupne zavedené viaceré úpravy, zamerané na zvýšenie robustnosti voči šumu, filtrovaniu a neznámemu časovému výrezu.

Spektrogram bol spracovaný v logaritmickej mierke a obmedzený na frekvenčné pásmo 300 – 3400 Hz, kde sa nachádza väčšina relevantnej hudobnej informácie. Na potlačenie vplyvu globálnych zmien amplitúdy bola použitá normalizácia po frekvenčných kanáloch.

Pre zvýšenie stability porovnania bol spektrogram agregovaný v časovej oblasti pomocou pooling-u (časová agregácia príznakov). Vzhľadom na rozdielnu dĺžku známych a testovacích nahrávok bola použitá posuvná analýza segmentov, pričom výsledná podobnosť bola určená maximálnou hodnotou korelácie normalizovaných príznakov. Tento prístup využíva vlastnosť Fourierovej transformácie, že časový posun nemení magnitúdu spektra.

Finálne riešenie dosiahlo na validačnej sade presnosť **Top-1 = 94 %** a **Top-5 = 100%**


4.1 Postup algoritmu

- 1) Každý testovací signál je spracovaný ako jednorozmerný časový signál so vzorkovacou frekvenciou 16 kHz.
- 2) Zo signálu je vypočítaná krátkodobá Fourierova transformácia s dĺžkou okna 512 vzoriek a 50% prekrytím.
- 3) Zo STFT je použitá iba amplitúdová zložka, ktorá je prevedená do logaritmickej mierky.
- 4) Spektrogram je obmedzený na frekvenčné pásmo 300 – 3400 Hz a normalizovaný po frekvenčných kanáloch.
- 5) Pre každú referenčnú nahrávku je aplikované posuvné okno dĺžky 5 sekúnd, ktoré sa posúva s krokom 0,125 sekundy.
- 6) Pre každý posun je vypočítaná podobnosť medzi testovacím a referenčným spektrogramom pomocou skalárneho súčinu.
- 7) Výsledná podobnosť je určená ako maximálna hodnota podobnosti zo všetkých posunov.

4.2 Ladenie parametrov

Počas vývoja riešenia boli experimentálne testované rôzne nastavenia kľúčových parametrov algoritmu popísaného v kapitole 4.1:

- **Krok posuvného okna:** testované hodnoty 0,5 s / 0,25 s / 0,125 s
menší krok viedol k vyššej presnosti identifikácie, avšak výrazne zvyšoval výpočtovú náročnosť, ako kompromis medzi presnosťou a časom výpočtu bol zvolený krok **0,125 s**.
- **Frekvenčné pásmo spektrogramu:** porovnané boli rôzne rozsahy frekvencií (napr. 50 – 5500 Hz); obmedzenia na pásmo **300 – 3400 Hz (telefónne pásmo)** sa ukázalo ako najvhodnejšie z hľadiska stability a robustnosti porovnania.
- **Normalizácia spektrogramu:** porovnané riešenia s a bez normalizácie po frekvenčných kanáloch, normalizácia výrazne znížila citlivosť na globálne zmeny amplitúdy a filtrovanie.



5. Záver

V rámci projektu bol navrhnutý a implementovaný systém na vyhľadávanie hudobných nahrávok založený na časovo-frekvenčnej analýze signálu. Riešenie využíva spektrogram, jeho normalizáciu a korelačné porovnanie pomocou posuvného okna. Postupným zlepšovaním základného riešenia sa podarilo výrazne zvýšiť presnosť identifikácie hudobných nahrávok.

Finálne riešenie dosiahlo vysokú úspešnosť na validačnej sade aj napriek prítomnosti šumu a filtrovaniu. Projekt potvrdil vhodnosť spektrogramovej reprezentácie a korelačných metód pre úlohy hudobného vyhľadávania.

Ako alternatívny prístup bol zvažovaný aj fingerprinting založený na detekcii lokálnych maxím v spektre podľa Wang (2003), ktorý je využívaný napríklad v systéme Shazam, avšak tento prístup nebol v rámci projektu detailne implementovaný.

Pri vypracovaní projektu som vychádzal z poznatkov z prednášok a poskytnutých python notebookov. Pri implementácii boli použité dostupné dokumentácie knižníc **NumPy**, **SciPy** a **Matplotlib** na porozumenie funkciám.